AI CUP 2024 秋季賽
根據區域微氣候資料預測發電量競賽報告

隊伍：TEAM_5926
隊員：郭智榮（隊長）、張晏誠
Private leaderboard：351729.7 / Rank 3

壹、環境

系統環境

本報告在競賽期間主要使用 Kaggle 平台進行程式撰寫和執行，該平台提供的免費 GPU 運算資源能協助訓練各種機器學習(Machine Learning, ML)或深度學習(Deep Learning, DL)的模型，而本報告最佳模型的復現流程能夠使用 Kaggle 平台或 Windows 系統進行，以便確保主辦方能夠復現該結果。

表 1 為本報告在 Kaggle 平台和 Windows 系統的配置，其中 Kaggle 平台環境由平台進行更新，本報告競賽期間皆是使用 2024/10/04 所更新的環境，目前平台已於 2024/12/03 進行環境更新，而 Windwos 系統則是採用 Anaconda 22.9.0 版本創建虛擬環境，並且統一使用 Python 3.10.14 版本。

表 1. 在 Kaggle 平台和 Windows 系統的配置

	Kaggle	Windows
CPU	Intel Xeon 2.20GHz	Intel i5-12400 2.5GHz
GPU	Nvidia P100	Nvidia RTX 3060 Ti

環境套件

本報告所安裝之 Python 套件版本在 Kaggle 和 Windows 系統上皆相同，並且統一使用 Python 3.10.14 版本，套件的名稱和版本如下表 2 所列。

表 2. 環境中所安裝的套件名稱和版本

套件名稱	套件版本
numpy	1.26.4
requests	2.32.3
pandas	2.2.3
tqdm	4.66.4
bs4	0.0.2
openpyxl	3.1.5
pvlib	0.11.1
lightgbm	4.2.0
pyopenssl	24.0.0
scikit-learn	1.2.2
matplotlib	3.7.5

競賽模型

本報告在競賽其中使用多種模型，而最佳成績所使用的模型為 Light Gradient Boosting Machine(LightGBM)，因此在報告中將以 LightGBM 為主進行說明。

額外資料集

本報告透過網路爬蟲(Web Crawler)蒐集中央氣象署的 CODiS 氣候觀測資料查詢服務平台[1]之公開氣候資料，該資料為台灣各地的氣候觀測站在每個小時所記錄的氣候資訊，包括但不限於溫度、濕度和降雨量等，這些特徵對於太陽能的發電量預測將提供極大的幫助，本報告所蒐集之特徵及其來源之氣候觀測站編號如下表 3 所列，其中東華為編號 1 至 14 的裝置，而花蓮市則為編號 15 至 17 的裝置，例如裝置編號 10 的 temp_cwb 資料來自 C0T9E0 的觀測站。

表 3. 所蒐集之氣候觀測站特徵與觀測站編號

特徵名稱	氣候觀測站編號		特徵說明
	東華	花蓮市	
pres_cwb	C0T9E0	466990	每小時氣候觀測站的氣壓
temp_cwb	C0T9E0	466990	每小時的氣候溫度(℃)
rh_cwb	C0T9E0	466990	每小時的相對溼度(%)
precp_cwb	C0T9E0	466990	每小時的降雨量(mm)
rad_cwb	C0Z100	466990	每小時的全天空日射量(MJ/m^2)
sun_cwb	466990	466990	每小時的日照時數(h)
visb_cwb	466990	466990	每小時的能見度(km)
uvi_cwb	466990	466990	每小時的紫外線指數
cloud_cwb	466990	466990	每小時的雲量，分級為 0~10

除氣候觀測站資料之外，本報告也使用 pvlib 套件[2]計算其他有利於太陽能發電量預測的特徵，該套件透過經緯度、時間、氣候溫度和氣壓等資訊計算各個特徵數值，其中經緯度由主辦方所提供之競賽與資料格式說明文件獲得，而氣候溫度和氣壓則是氣候觀測站的資料，時間則以每筆資料的時間特徵為主，套件所計算的特徵如表 4 所列，而圖 1 和圖 2 為天頂角、視仰角及方位角示意圖。

表 4. 由 pvlib 計算所得的特徵

特徵名稱	特徵說明
zenith	天頂角(°)，即天頂與太陽的角度
apparent_zenith	考慮大氣折射後的天頂角(°)
elevation	視仰角(°)，即地平線與太陽的角度
apparent_elevation	考慮大氣折射後的視仰角(°)
azimuth	方位角(°)，觀測點北方到太陽方位的角度
dni	直接輻射(W/m^2)，垂直於太陽光的輻射量
dhi	散射輻射(W/m^2)，大氣散射的輻射，不包含 dni
ghi	總輻射(W/m^2)，總和 dni 和 dhi 的輻射量

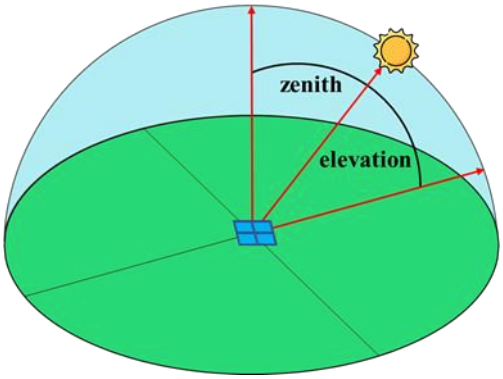


圖 1. 天頂角和視仰角的示意圖

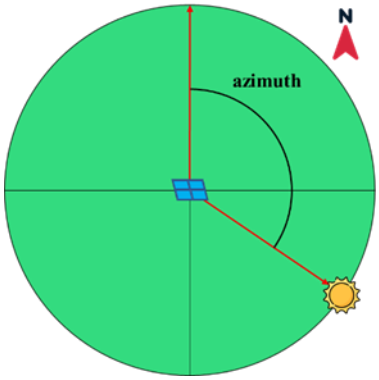


圖 2. 方位角的示意圖

貳、演算方法與模型架構

模型架構

LightGBM 是由微軟(Microsoft)在 2017 年 4 月提出的開源機器學習框架，其基於梯度提升決策樹(Gradient Boosting Decision Tree, GBDT)的框架，目的是改善傳統 GBDT 處理大規模資料時速度過慢的問題，因此 LightGBM 對於本次競賽中高達約 1,375,000 筆資料的訓練集而言是非常合適的方法，同時其具備自動處理缺失值的能力，能藉此改善部分特徵具有缺失值的狀況。

LightGBM 採用 Leaf-wise 的方式進行訓練，並透過 Gradient-based One-Side Sampling(GOSS)和 Exclusive Feature Bundling(EFB)演算法降低其計算量，其訓練時的生長方式如下圖 3 所示，每次都會使用直方圖演算法找到增益最大的葉節點進行分裂，這種方式相比於使用 Level-wise 的 XGBoost 方法，在相同分裂次數下會得到更好的表現，而 Level-wise 是指如圖 4 中以層為主的生長方式。

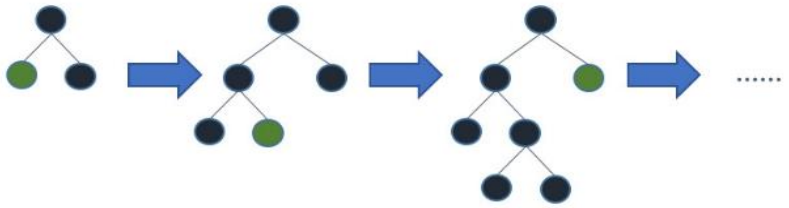


圖 3. Leaf-wise 的方法

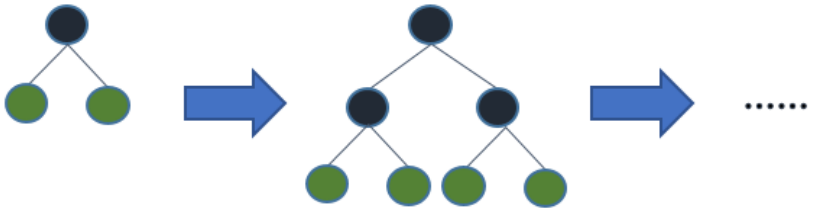


圖 4. Level-wise 的方法

模型參數

因為本報告是在競賽較後期才使用 LightGBM，因此對於模型的參數並沒有做太多嘗試，主要仍測試不同特徵組合對於模型分類表現的差異；對於模型參數則較多調整 num_boost_round 和 early_stopping_round 的設置，前者用於控制模型訓練的迭代次數，而後者則是當評估指標在連續幾次迭代後仍沒有提升就會停止訓練，其調整後的差異在分析部分會進一步說明。

參、創新性

因比賽時程較為緊湊，因此在本次參加競賽過程中並沒有太多時間對資料集或各個模型進行太多調整，但本報告引入氣候觀測站的資料，包括氣壓、溫度、全天空日射量等關鍵特徵，這些氣候資料對模型預測發電量起到重要的影響，並透過 pvlib 套件計算太陽位置特徵，包括天頂角、視仰角、方位角等，再結合直接輻射、散射輻射等輻射量估算值，豐富模型預測時的輸入特徵。並且本報告參與競賽期間也嘗試透過不同模型觀察其預測太陽能發電量的表現，除 LightGBM 外也使用長短期記憶(Long Short-term Memory, LSTM)、隨機森林(Random Forest)等模型。最後，本報告也使用不同時間特徵的表達方式提升模型預測表現，其中就包括基本的月、日、時和分，以及能夠保持時間連續性且反映週期特性的正弦和餘弦的時間特徵。

肆、資料處理

裝置資訊

本次競賽共有 17 組裝置，除訓練集所提供之特徵外，在資料格式說明文件中也提供各裝置的座標與朝向，本報告會將原始度分秒的經緯度轉換為十進位度數表示，其中編號 17 的裝置並沒有提供座標，而其備註有提到與花蓮市氣候站距離約 2.8 公里，圖 5 是本報告在地圖上繪製其可能的範圍，但由於周邊住家較多，因此最後仍以較保守的方式將編號 17 的經緯度設為氣候站的經緯度，而裝置的朝向則不另外補值。



圖 5. 花蓮市氣候站半徑 2.8 公里的範圍

時間特徵

太陽能的發電量是與時序資料高度相關的議題，因此本報告除了基本的月、日、時和分的表達方式外，也透過能夠保持時間連續性且反映週期特性的正弦和餘弦的時間循環特徵，圖 6 為本報告繪製的每分鐘的正弦和餘弦數值，這種表達方式能避免使用基本特徵時，模型可能無法學習到 5 點 59 分和 6 點 0 分的時間連續性。

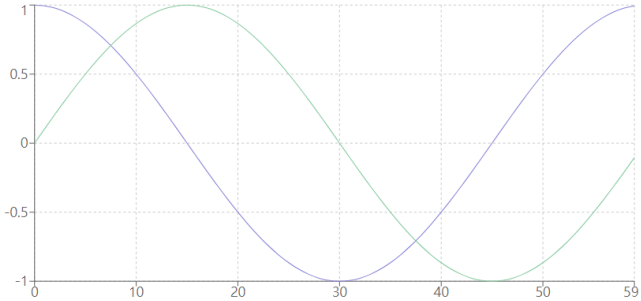


圖 6. 每分鐘的正弦(綠)和餘弦(藍)數值

除了時間循環特徵外，本報告也使用一天中的第幾分鐘和一年中的第幾天的時間序列特徵，前者代替時和分，而後者則代替月和日。對於發電量而言季節是非常重要的影響因素，但本報告認為單純將季節切分成 4 種作為特徵，可能會使模型在季節交換期間較容易產生誤差，且各月份資料量有明顯落差也使各個季節資料不平衡的狀況更嚴重，因此透過一年中的第幾天讓模型依照天數區分季節的同時也能保留日期的時間連續性。

特徵缺失值

表 5 為外部資料集各個特徵的缺失值數量，其中氣候觀測站的 cloud_cwb 和 visb_cwb 為缺失值最多的特徵，主要原因是 cloud_cwb 的數值為 0 時不會被記錄導致缺失，而 visb_cwb 雖然沒有明確說明數值範圍，但本報告觀察數據後認為是因為能見度超過 25 公里便不會記錄，因此才導致 visb_cwb 有較多缺失值，此外由 pvlib 計算的 apparent_zenith, apparent_elevation, dni, dhi 和 ghi 因為需要溫度和氣壓進行計算，因此當溫度和氣壓出現缺失值時這些特徵將無法被計算。

表 5. 外部資料集各個特徵的缺失值數量

特徵名稱	缺失值的數量	
	訓練集	測試集
pres_cwb	480	12
temp_cwb	480	12
rad_cwb	60	12
sun_cwb	2,643	0
visb_cwb	839,949	6,000
uvi_cwb	0	0
cloud_cwb	839,949	6,000
zenith	0	0
apparent_zenith	480	12
elevation	0	0
apparent_elevation	480	12
azimuth	0	0
dni	480	12
dhi	480	12
ghi	480	12

伍、訓練方式

本報告將針對最佳模型的完整訓練方式進行說明，其整體流程如圖 7 所示，在最初會將競賽訓練集和競賽測試集分別進行相同的資料處理步驟，在資料處理時會合併外部資料集如氣候觀測站資料集和 pvlib 計算的太陽與輻射量資料集再進行資料前處理，前處理包含上述所提到的裝置資訊和時間特徵等，並且會進行缺失值處理，最後再從中挑選模型訓練所需特徵，而挑選特徵後會分為訓練集和測試集。首先，訓練集會分為 5 等份進行 5 折交叉驗證(5 Folds Cross Validation)的模型評估，藉此觀察模型在 outside 資料的表現；此外，完整訓練集也會用於訓練模型，並從中提取裝置編號 17 的資料作為 inside 的驗證集，而完整訓練集所訓練的模型除了對驗證集做模型評估外，也會對測試集進行預測並輸出預測結果，此結果便是本報告提交至競賽網站的答案。

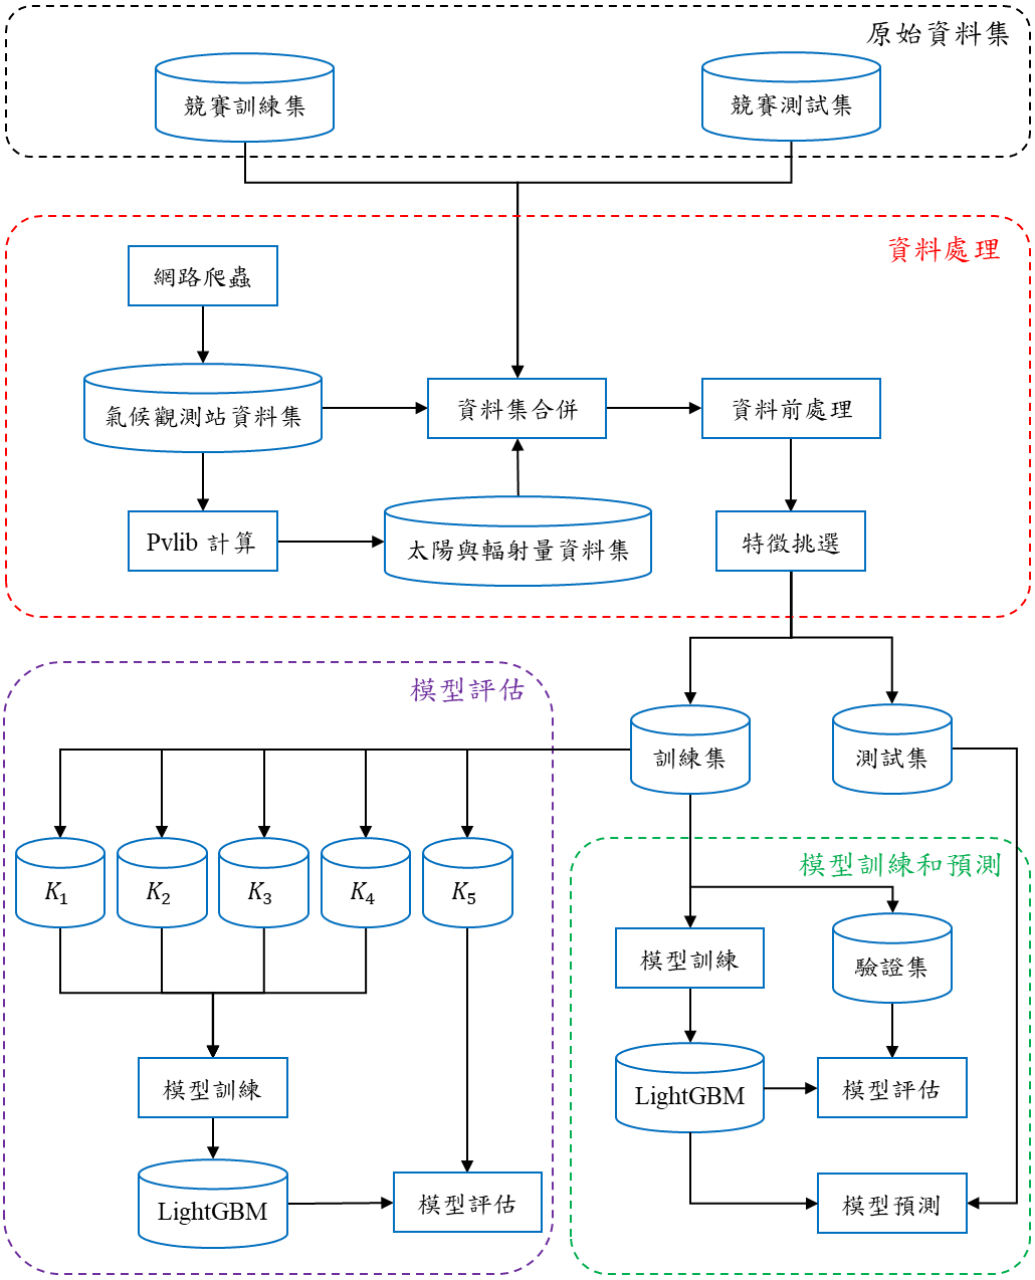


圖 7. 模型訓練和評估的流程圖

陸、分析與結論

本報告在競賽期間總共提交達 55 次答案，其中有 2 次因在 23 點 59 分進行提交導致上傳失敗，而其餘的 53 次提交中，不僅測試許多種的特徵組合，也使用不同模型進行訓練和預測，其中除了成績最佳的 LightGBM 外，還包括 LSTM 和隨機森林，本報告將在本節對競賽過程的各種實驗和結果進行討論，其模型編號對應提交答案的備註，而驗證集使用平均絕對誤差(Mean Absolute Error, MAE)。

時序模型的表現

在競賽初期，本報告訓練 LSTM 使用前 2 個小時的 12 筆資料預測發電量，該模型類似競賽提供的 baseline code 透過所預測的發電量持續進行預測，並搭配不同特徵組合進行初步實驗，其實驗結果如表 6 所示。首先，編號 01 的模型使用發電量作為唯一輸入特徵，但持續使用預測的發電量進行後續預測會使得預測值持續上升或停滯在最高點如圖 8 所示，這主要是因為模型只使用發電量作為輸入特徵，且早上 7 點至 9 點間的發電量為上升趨勢，導致 LSTM 所預測的發電量會越來越高，最後當發電量到達峰值後便會停滯，因此該模型的預測都會停滯在其峰值 875.91。要解決此問題最簡單且有效的方式便是加入時間特徵，因此本報告在編號 02 的模型加入一天當中的第幾分鐘作為時間特徵，並藉此使其絕對誤差下降約 180 萬；最後透過加入氣候觀測站溫度及調整模型大小等方式也僅能讓其絕對誤差降低至 116 萬，是本報告在競賽期間時序模型的最低誤差。

表 6. 時序模型 LSTM 的表現

編號	驗證集誤差	公開測試集分數	隱藏測試集分數
01	59.6660	3084361.61	2986317.19
02	59.8920	1298434.37	1489688.15
25	65.5740	1167823.80	1391573.83

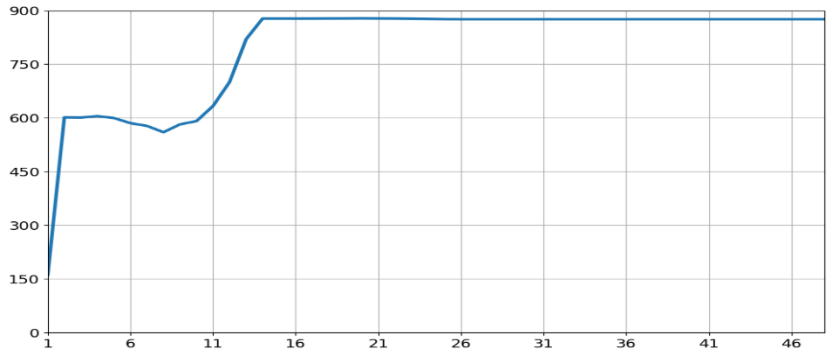


圖 8. 編號 01 的模型預測第一題的結果

迴歸模型的表現

本報告持續調整時序模型並提交達 27 次答案，但發現其誤差仍維持在 120 萬上下，因此嘗試將發電量從特徵移除，並使用裝置編號、月、日、時和分共 5 個特徵訓練單步預測的 LSTM 模型就使其誤差下降至 90 萬，再加入外部資料集的部分特徵後更使其下降至 43.6 萬，是 LSTM 在競賽期間的最低誤差。而本報告也嘗試在同樣的特徵組合下訓練不同模型，其結果如表 7 所示，因為本報告將外部資料的輻射量加入至特徵組合中，因此導致 LSTM 在沒有特別調整架構的狀況下誤差上升，但可以發現 LightGBM 的誤差相較另外兩種模型更低許多。

表 7. 不同模型的表現

編號	模型	驗證集誤差	公開測試集分數	隱藏測試集分數
43	LSTM	98.5305	528891.51	628486.09
44	隨機森林	48.3712	442071.57	471636.29
45	LightGBM	33.0061	335781.06	357147.03

模型迭代次數

表 8 是 LightGBM 在不同迭代次數的表現差異，編號 49 與 50 的迭代次數皆被設為 50,000 次，但前者的 early_stopping_round 被設為 20，後者則不提前停止訓練，可以發現模型在訓練達 50,000 次迭代時仍有進步，而後續模型再持續迭代至 500,000 次後的誤差雖然仍有下降，但從測試集分數能發現模型可能已經出現過擬合(Overfitting)的狀況。

表 8. 不同迭代次數的分數差異

編號	迭代次數	驗證集誤差	公開測試集分數	隱藏測試集分數
49	32,828	25.1282	328085.53	354718.12
50	50,000	21.5063	326660.64	353647.91
52	500,000	5.0382	328168.13	358280.25

時間特徵

由時序模型的實驗能得知時間特徵對於預測發電量有非常重要的影響，不同季節和時間的氣候資訊可能相似但發電量卻會有巨大落差，例如本次競賽訓練集中 7 月 23 日的 16 點 32 分氣候溫度為 23.1 度，而其發電量為 0.32，但 1 月 20 日的 13 點 11 分溫度同樣為 23.1 度，但發電量卻高達 1932.52，雖然可能還有存在其他如是否陰天、日射量和太陽照射角度等因素影響，但 1 月和 7 月的季節不同使其每天各個時間點的平均溫度出現差異也是預測發電量時很重要的影響因素，因此搭配合適的時間特徵便能使模型的表現提升。

本報告使用一年中的第幾天作為表達日期與季節的時間特徵，因為單純使用月、日和季節可能會使模型在季節交替時的表現較差，例如 8 月 30 日與 9 月 1 日的天氣相似，但模型輸入特徵(月, 日, 季節)的數值為(8, 30, 夏)和(9, 1, 秋)，即便這兩筆資料的日期僅有相隔一天，但模型在預測時可能會認為其時間特徵的數值差異較大，且從圖 9 中可以發現各個月份間的資料數量不平衡，這種現象可能會導致模型在特定季節和月份的表現較差。

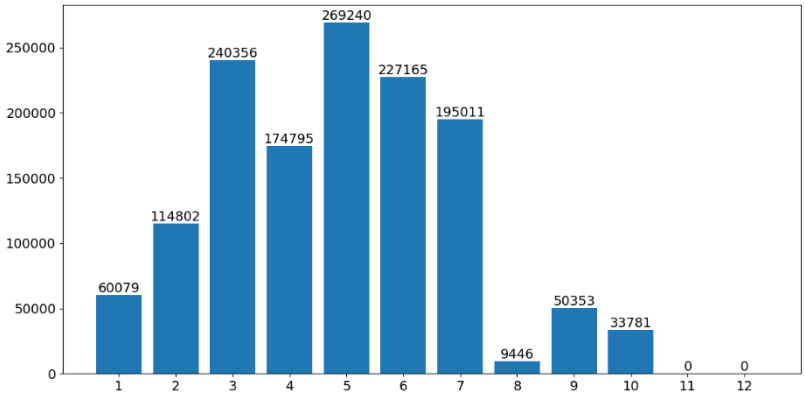


圖 9. 訓練集中各個月份的資料數量

特徵組合

本報告在競賽期間逐步加入外部資料集的特徵並觀察其變化與各種特徵組合的效果，其中最重要的特徵為氣候觀測站的全天空日射量 rad_cwb，該特徵是由氣候觀測站實際測量的太陽輻射量，相較 pvlib 透過其他資訊所計算的輻射量會更接近真實情況下的數值，因此可以在圖 10 中發現其重要性明顯高於另外三種輻射量特徵。而第二重要的特徵為裝置編號 LocationCode，該特徵能使模型識別不同裝置，若不使用裝置編號作為特徵，可能會使模型無法區別東華和花蓮市的裝置導致誤差提升。而氣候溫度 temp_cwb 雖然重要性較低，但在實際的測試中發現溫度特徵會使誤差大幅下降，在表 9 中的編號 31 是 LSTM 使用裝置編號、月、日、時和分的表現，而編號 33 為加入溫度 temp_cwb 後的表現，分數由 90 萬下降到 58 萬，並在編號 37 中加入全天空日射量 rad_cwb 後進一步下降到 44 萬。而其他特徵雖然沒有與上述三種特徵一樣讓誤差明顯下降，但任一特徵被移除後仍然會使誤差出現 3000 至 20000 的些微上升。

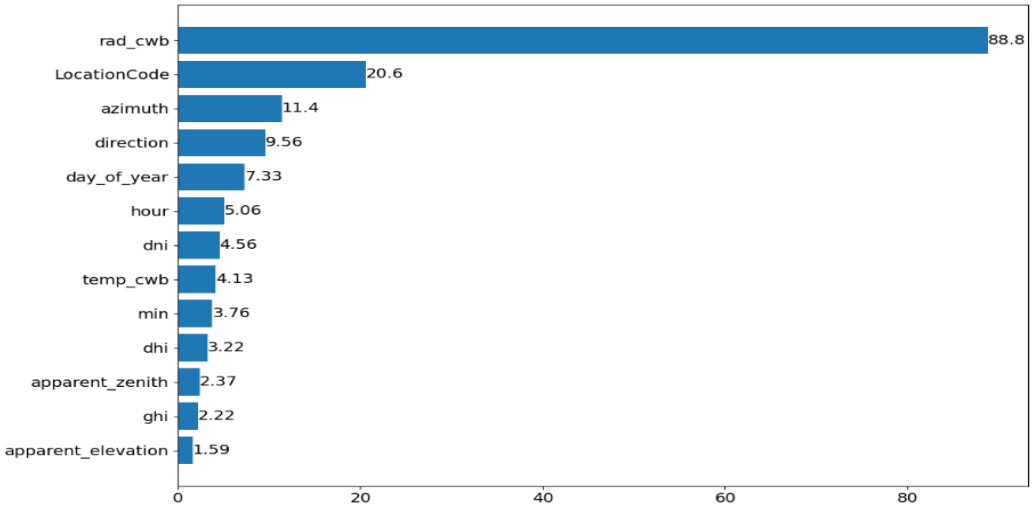


圖 10. 最佳模型的特徵重要性

表 9. 逐步增加氣候觀測站特徵的 LSTM 模型表現

編號	驗證集誤差	公開測試集分數	隱藏測試集分數
31	437.4970	905712.28	875117.56
33	100.1406	589872.58	689962.12
37	76.1565	447346.19	540854.53

資料採樣頻率

本次競賽所提供的訓練集與測試集分別採用 1 分鐘 1 筆資料與 10 分鐘 1 筆資料的方式，本報告則會將其採樣頻率統一，因此訓練集會每 10 分鐘合併為 1 筆並取其特徵的平均值，而測試集也會被細分為每分鐘 1 筆資料。對輸入時序特徵的 LSTM 採用 10 分鐘為採樣頻率，主要是因為其預測時會使用預測值持續進行預測，因此本報告認為將採樣頻率設為 1 分鐘會讓誤差推疊的情況更嚴重。但是單步預測的 LSTM、隨機森林和 LightGBM 並不會使用預測值進行預測，因此能避免誤差推疊的情況發生，故其訓練集會使用每分鐘 1 筆的採樣頻率，而預測時則分為每分鐘 1 筆和 10 分鐘 1 筆做測試，表 10 是同個模型在測試集為不同採樣頻率時的表現，編號 38 使用 10 分鐘預測 1 筆的方式；而編號 39 則是每分鐘都會預測 1 筆，最後再將每 10 分鐘的預測取平均值作為答案。

表 10. 測試集使用不同採樣頻率的表現

編號	驗證集誤差	公開測試集分數	隱藏測試集分數
38	83.6123	449848.59	563597.41
39		436740.64	547317.84

結論

雖然本報告在公布測試集前已經針對訓練集所提供的特徵進行初步實驗，但後續因為測試集僅有提供裝置編號和時間，因此在競賽較初期時策略的調整較為頻繁，而部分實驗也因有限的時間和提交次數而無法完善，本報告也曾嘗試透過訓練集訓練迴歸模型使用裝置編號和時間預測其他訓練集特徵，但因為這種方式可能會使預測特徵的誤差影響到後續預測的發電量，因此最後並沒有將此實驗的結果提交。其他還有部分實驗是已經進行並有提交，但因為次數不足而無法進行探討的實驗，例如多模型堆疊和僅使用部分時間資料的實驗，本報告隱藏測試集最佳模型就是僅保留 06:00~19:00 的訓練資料進行訓練的模型，但因為還有其他變因而無法與其他模型進行合理的比較，因此最後並沒有探討該項目。

柒、程式碼

Github 連結：https://github.com/Guo0911/Prediction_Power_Generation

本報告在 Github 的 README 最下方已有附上程式執行流程，並在 notebook 資料夾中提供 Kaggle 執行後的結果可供查看，若有需要也可以在 README 找到對應的 Kaggle 連結察看輸入與輸出的資料集。為避免混淆，程式碼中僅提供最佳模型的復現，如有需要進一步的說明或其他非最佳模型的程式碼，本報告在收到通知後會盡快補上相應資料。

捌、使用的外部資源與參考文獻

[1] 中央氣象署. (n.d.). CODiS 氣候觀測資料查詢服務. https://codis.cwa.gov.tw/StationData

[2] Pvlib. (n.d.). Pvlib-Python. Github. https://github.com/pvlib/pvlib-python